

머신러닝의 성능 향상을 위한 데이터 스케일링 기법 분석

강태형 · 주윤성 · 권용현 · 이윤섭 · 이영우*

부산가톨릭대학교

Analyzing Data Scaling Techniques to Improve the Performance of Machine Learning

Tae-Hyeong Kang · Yoon-seong Joo · Yong-heon Kwon · Yun-seop Lee · Young-woo Lee*

Catholic University of Pusan

E-mail : xogud1465@gmail.com / freezino@kakao.com / dydgus9920@naver.com /

sella45@naver.com / ywlee@cup.ac.kr

요 약

현대 사회에서 AI 사용이 점점 더 많아지며 모델 성능의 중요성 또한 증가하고 있다. 모델 성능은 코드와 알고리즘에만 영향을 받을 뿐만 아니라, 데이터의 품질과 전처리 또한 모델 성능에 큰 영향을 준다. 데이터 스케일링은 이러한 전처리 단계 중 하나로, 데이터의 분포를 일정하게 조정해준다.

본 연구는 SVM 모델을 사용하여 원본 데이터와 스케일링한 데이터를 각각 비교, 분석하여 데이터 스케일링이 모델의 성능을 향상시켜주는지 확인하고자 한다.

ABSTRACT

In modern society, AI use is increasing and the importance of model performance is also increasing. Model performance is not only affected by code and algorithms, but also the quality and preprocessing of data have a great influence on model performance. Data scaling is one of these preprocessing steps, and the distribution of data is constantly adjusted.

This study aims to check whether data scaling improves the performance of the model by comparing and analyzing the original data and the scaled data using the SVM model, respectively.

키워드

Data Scaling, scikit-learn, SVM, Normalization

I. 서 론

현대 사회에서 AI 사용이 점점 더 많아지며, 모델 성능의 중요성 또한 증가하고 있다. 모델 성능은 코드와 알고리즘에만 영향을 받을 뿐만 아니라, 입력받는 데이터의 품질과 전처리 또한 모델 성능에 큰 영향을 준다. 데이터 입력 단계에서 데이터의 단위차이나 크기에 따라 상대적으로 작은 특성이 무시당하거나 중요하지 않은 특성이 크게 작용하여 모델 성능에 영향을 주게 된다. 데이터 스케일링은 데이터 전처리 단계 중 하나로, 데이터의 분포를 일정하게 조정해주는 방법이다. 본 논문은 데이터 스케일링 기법을 적용한 데이터와 원본 데이터를 각각 비교, 분석하고자 한다.

II. 이론적 배경

데이터 셋에서 피쳐마다 데이터의 범위가 다를 수 있고, 범위 차이가 클 경우 범위가 작은 피쳐는 무시 당할수 있다. 이런 데이터를 그대로 학습할 경우 최적화 과정에서 그레이디언트 소실 문제가 발생하거나, 값이 0으로 수렴하거나 무한으로 발산하는 경우도 발생할 수 있다. 데이터 스케일링은 모든 피쳐들의 데이터 분포와 범위를 일정하게 조정해 줌으로써, 각 피쳐가 무시되지 않고 동일한 영향을 미칠 수 있도록 하는 중요한 전처리 작업이다[1]. Sklearn에서 제공하는 RobustScaler는 이상치에 덜 민감한 방식으로 데이터를 스케일링하는 기법이다.

$$X_s = \frac{X - \text{median}}{\text{IQR}}$$

* 교신저자

$$IQR = Q3 - Q1$$


RobustScaler는 중앙값을 0으로 설정하고, IQR을 1로 설정하여 각 피처를 스케일링한다. 피처별로 중앙값을 기준으로 스케일링을 수행하여 이상치가 결과에 미치는 영향을 최소화 할 수 있다.[2]

III. 데이터 스케일링 적용 비교


1. 데이터 수집

Sklearn에서 제공해주는 유방암 데이터셋에 분류 문제에 주로 사용되는 거리기반 알고리즘인 SVM 모델을 사용하여 데이터들을 악성, 양성으로 분류 하였다.

2. 데이터 스케일링 미적용



[그림1] 스케일링을 적용하지 않은 Confusion Matrix




[그림2] 스케일링을 적용하지 않은 Classification Report

데이터 스케일링을 하지 않은 원본 데이터를 그대로 모델에 학습 시킬 경우, [그림1]과 같이 악성


데이터 분류를 거의 수행하지 못하는 모습을 보여 준다.

또한 [그림2]에서는 악성 데이터 분류에 매우 낮은 재현율을 보여준다.

3. RobustScaler 적용



[그림3] RobustScaler를 적용한 Confusion Matrix



[그림4] RobustScaler를 적용한 Classification Report

RobustScaler를 적용한 [그림3]에는 악성, 양성 데이터를 제대로 분류 하였고, [그림4]에선 악성과 양성 데이터 모두 높은 정밀도와 재현율을 보여준다.

결과적으로 원본데이터를 적용한 [그림1], [그림2]와 RobustScaler를 적용한 [그림3], [그림4]를 비교해 봤을 때 데이터 스케일링을 적용하는 것이 모델의 성능을 효과적으로 향상 시켜준다.

IV. 결 론

모델 학습에서 상대적으로 중요하지 않은 피처가 데이터 범위가 크다는 이유만으로 중요한 피처로 적용될 수 있다. 특히 복잡하고 높은 차원의 데이터일수록 특정 피처가 과도하게 모델 학습에 영향을 미쳐 모델의 성능 저하를 일으킬 수 있다. 데이터 스케일링을 적용함으로써 모든 피처가 반영

되어 모델의 일반화 성능을 향상시키는데 중요한 역할을 한다. SVM과 KNN과 같은 거리기반 알고리즘에선 데이터의 스케일에 민감하기 때문에, 데이터 스케일링은 필수적인 단계이다. 본 논문에선 하나의 스케일러만 분석해보았고, 다양한 상황에서 사용해보지 않았기 때문에 추후 원본 데이터가 아닌 다른 스케일러를 적용하여 각 상황별로 어떤 스케일러를 사용하는게 좋을지 분석할 예정이다.

References

- [1] 김영원, 이수진. (2022-07-14). XGBoost 기반 침입탐지모델을 위한 데이터 스케일링 및 특성선택 기법 연구. 한국컴퓨터정보학회 학술 발표논문집, 제주.
- [2] [Internet]. Available : <https://wikidocs.net/89704>